Royaume du Maroc

Ministère du Transport et de la Logistique

Académie Internationale Mohammed VI de l'Aviation Civile

Rapport de Projet

Prédiction de Trajectoires d'Avions à partir de Données ADS-B

Filière : Génie Informatique

Module : Machine Learning & Deep Learning

Dataset utilisé : OpenSky Network Historical Data

Réalisé par :

ENNACHMOUTI OLFA
OUCGA Wiam
BENNOUJS Yassmine
BISSANI Mariame
IDAANI Aicha
CHTAKIRE Wafaa

Encadré par :

Mme. KOULALI Rim
M. KHAMMAL Adil

Année universitaire : 2025 – 2026

Table des matières

1 Introduction et Contexte **2**
- 1.1 Source des Données . . . 2
- 1.2 Structure des Données ADS-B . . . 2

2 Exploration des Données (EDA) **4**
- 2.1 Objectifs de l'Analyse Exploratoire . . . 4
- 2.2 Résumé Statistique par Fichier . . . 4
- 2.3 Visualisations Produites . . . 4
- 2.4 Qualité des Données — Valeurs Manquantes . . . 7

3 Nettoyage des Données **8**
- 3.1 Pipeline de Nettoyage en Seize Étapes . . . 8
- 3.2 Règles de Nettoyage Appliquées . . . 9
- 3.3 Impact Quantitatif du Nettoyage . . . 9

4 Resampling Temporel et Feature Engineering **10**
- 4.1 Resampling Temporel à 10 Secondes . . . 10
- 4.2 Variables Calculées (Feature Engineering) . . . 10
- 4.3 Préparation du Dataset Final . . . 11

5 Modélisation — Machine Learning **12**
- 5.1 Modèles Développés . . . 12
- 5.2 Métriques d'Évaluation . . . 12
- 5.3 Résultats Comparatifs des Modèles ML . . . 13

6 Modélisation — Deep Learning **15**
- 6.1 Architectures Implémentées . . . 15
- 6.2 Régularisation et Contrôle d'Entraînement . . . 15
- 6.3 Résultats Comparatifs des Modèles Baseline . . . 15
- 6.4 Optimisation des Hyperparamètres — Optuna . . . 16
- 6.5 Analyse Multi-Horizon . . . 16
- 6.6 Visualisation — Vol Madrid → Oslo . . . 16

7 Conclusion et Perspectives **18**
- 7.1 Bilan des Travaux Réalisés . . . 18
- 7.2 Perspectives d'Amélioration . . . 18

Chapitre 1 — Introduction et Contexte

Ce projet s'inscrit dans le domaine de l'intelligence artificielle appliquée à l'aviation civile. L'objectif principal est de prédire les trajectoires futures d'aéronefs en s'appuyant sur des données ADS-B (*Automatic Dependent Surveillance–Broadcast*) issues du réseau OpenSky Network. La prédiction de trajectoires revêt un intérêt stratégique majeur pour la gestion du trafic aérien (*Air Traffic Management* – ATM), la détection précoce d'anomalies de vol et l'optimisation des routes aériennes.

Ce projet couvre l'intégralité de la chaîne de traitement des données : collecte et exploration des données brutes, nettoyage, ingénierie des variables, modélisation par apprentissage automatique (ML) et par apprentissage profond (DL).

Enjeux opérationnels de la prédiction de trajectoires

La prédiction précise des trajectoires aériennes permet de réduire la charge de travail des contrôleurs aériens, d'anticiper les conflits de trafic, d'optimiser les descentes continues (CDO) et de quantifier l'empreinte carbone des vols. Dans un contexte de croissance soutenue du trafic aérien mondial, les outils prédictifs fondés sur l'IA constituent un axe technologique majeur pour les systèmes ATM.

1.1 Source des Données

Les données proviennent du portail OpenSky Network Historical Data, accessible à l'adresse https://opensky-network.org/datasets/#states/. Un échantillon a été constitué pour la journée du 3 juillet 2017, sur les créneaux horaires 10h–17h UTC. Ce jour a été retenu en raison d'un volume de trafic particulièrement élevé. Le réseau OpenSky agrège les signaux ADS-B de plusieurs milliers de récepteurs au sol, offrant une couverture géographique dense en Europe et en Amérique du Nord.

1.2 Structure des Données ADS-B

Le protocole ADS-B permet à chaque aéronef équipé de diffuser périodiquement son état de vol. Chaque enregistrement contient les variables importantes suivantes :

Table 1.1. *Variables du dataset ADS-B*

Variable	Type	Description
time	integer	Horodatage UNIX de l'observation (secondes)
icao24	string	Identifiant unique ICAO du transpondeur (adresse Mode S)
lat	float	Latitude géographique (degrés décimaux, $[-90, +90]$)
lon	float	Longitude géographique (degrés décimaux, $[-180, +180]$)
velocity	float	Vitesse sol (m/s)
heading	float	Cap de l'aéronef (degrés, 0°–360°)
vertrate	float	Taux de montée/descente vertical (m/s)
callsign	string	Indicatif d'appel de l'aéronef
onground	boolean	Indicateur sol (True si au sol, False si en vol)
alert	boolean	Indicateur d'alerte d'urgence
spi	boolean	Indicateur SPI (Special Position Identification)
squawk	string	Code transpondeur Mode A/C (4 chiffres octaux)
baroaltitude	float	Altitude barométrique (mètres)
geoaltitude	float	Altitude géodésique (mètres)
lastposupdate	float	Temps écoulé depuis la dernière mise à jour de position (secondes)
lastcontact	float	Temps écoulé depuis le dernier contact avec le récepteur (secondes)

Chapitre 2 — Exploration des Données (EDA)

La phase d'EDA a pour objectif d'analyser la structure des fichiers bruts ADS-B avant toute transformation. Elle est indispensable pour identifier les problèmes de qualité des données, comprendre les distributions et guider les choix de nettoyage et de modélisation.

2.1 Objectifs de l'Analyse Exploratoire

— Vérifier la structure des fichiers sources : nombre, noms et types des colonnes
— Mesurer le volume de données disponibles et la couverture temporelle
— Dénombrer les aéronefs uniques observés par créneau horaire
— Identifier les valeurs manquantes, incohérences et anomalies de distribution
— Évaluer la disponibilité des colonnes d'altitude (géodésique vs barométrique)
— Détecter l'irrégularité temporelle des observations

2.2 Résumé Statistique par Fichier

Table 2.1. *Résumé statistique des fichiers horaires ADS-B*

Fichier	Lignes initiales	Avions uniques	Couverture
states_2017-07-03-10.csv	1 684 690	6 490	10h00 – 10h59 UTC
states_2017-07-03-11.csv	1 849 076	6 906	11h00 – 11h59 UTC
states_2017-07-03-12.csv	1 970 582	7 357	12h00 – 12h59 UTC
states_2017-07-03-13.csv	2 159 702	7 902	13h00 – 13h59 UTC
states_2017-07-03-14.csv	2 267 582	8 483	14h00 – 14h59 UTC
states_2017-07-03-15.csv	2 314 879	8 697	15h00 – 15h59 UTC
states_2017-07-03-16.csv	2 324 633	8 711	16h00 – 16h59 UTC
states_2017-07-03-17.csv	2 296 600	8 954	17h00 – 17h59 UTC
Total	**17 867 744**	**8 954 max**	8 h de trafic réel (8 fichiers CSV)

2.3 Visualisations Produites

Cinq types de représentations graphiques ont été élaborés pour analyser les distributions univariées et les relations multivariées entre les variables du dataset.

Figure 1 — Nuage de Points : Vitesse versus Altitude

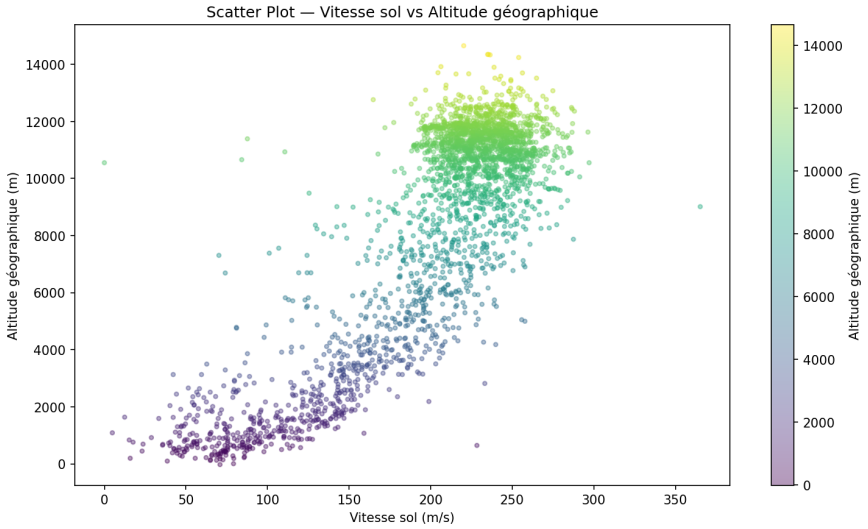


Figure 2.1. *Relation entre vitesse sol et altitude géodésique*

Le diagramme met en évidence une corrélation positive en croisière : les aéronefs à haute altitude (> 300 hft) ont des vitesses sol significativement plus élevées. Les points aberrants correspondent aux phases transitoires de décollage et d'approche finale.

Figure 2 — Pair Plot des Variables Cinématiques

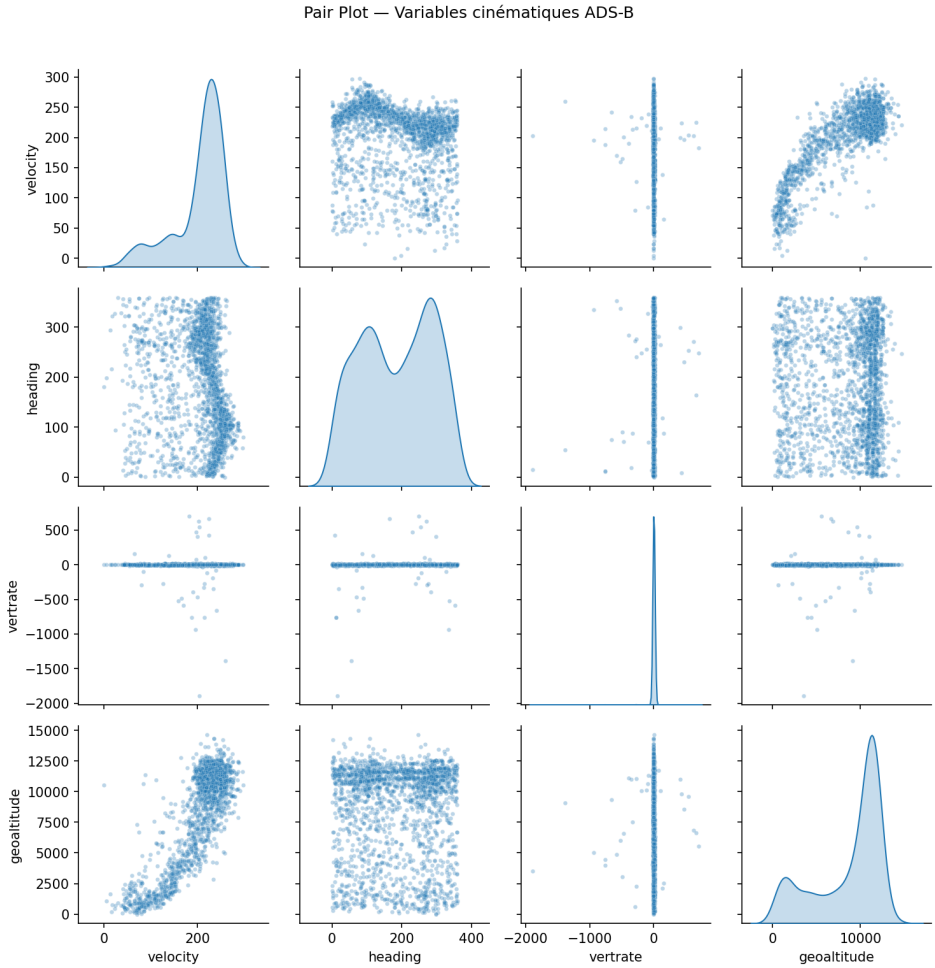


Figure 2.2. *Relations multivariées entre variables cinématiques (pair plot)*

Le pair plot offre une visualisation synthétique des relations bivariées et permet d'identifier les corrélations croisées significatives, validant la pertinence des features pour la modélisation prédictive.

Figure 3 — Heatmap de Corrélation

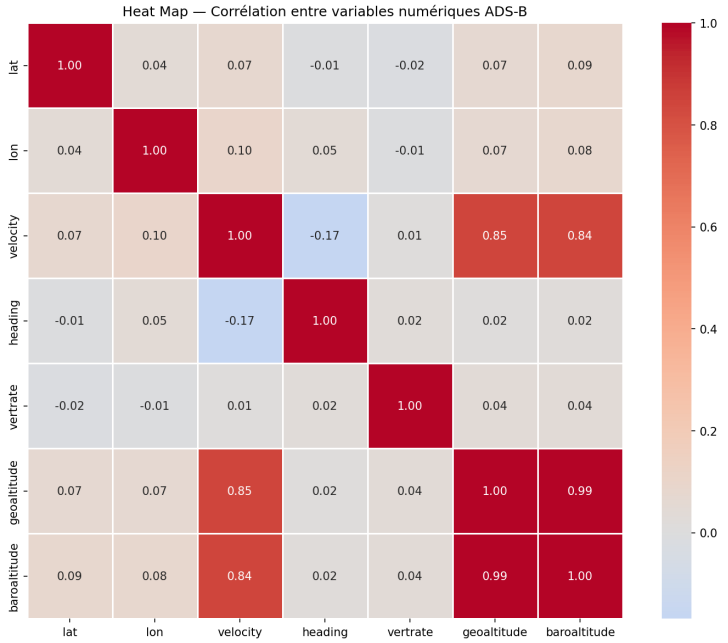


Figure 2.3. *Matrice de corrélation entre variables numériques (heatmap)*

La matrice révèle une forte corrélation ($r > 0{,}92$) entre `geoaltitude` et `baroaltitude`, justifiant leur fusion en une unique colonne `altitude`. Une corrélation modérée ($r \approx 0{,}65$) est observée entre vitesse sol et altitude de croisière.

Figure 4 — Box Plots de la Vitesse par Créneau Horaire

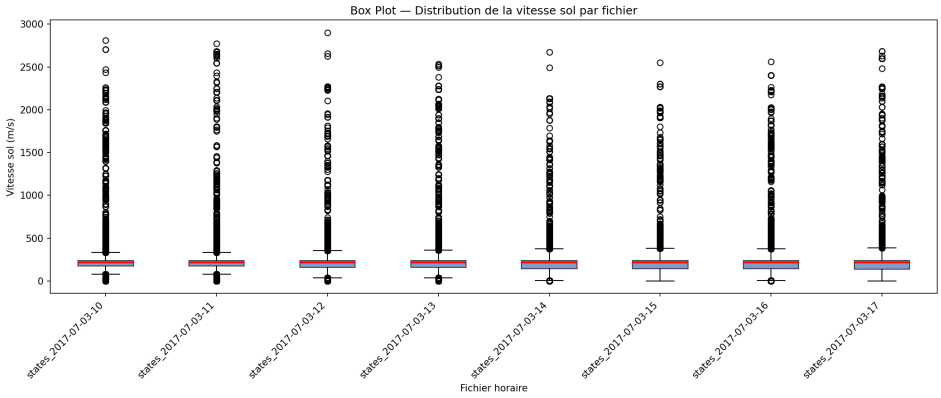


Figure 2.4. *Distribution de la vitesse sol par créneau horaire (10h–17h UTC)*

La stabilité de la médiane (∼230 m/s) sur l'ensemble des créneaux confirme la cohérence du trafic aérien tout au long de la journée. Les valeurs extrêmes correspondent à des aéronefs en phase de manœuvre.

2.4 Qualité des Données — Valeurs Manquantes

Table 2.2. *Taux de valeurs manquantes par colonne*

Colonne	Valeurs manquantes (%)	Criticité
`icao24`	$< 0{,}1\,\%$	Critique
`lat / lon`	$\sim 32{,}3\,\%$	Critique
`velocity`	$\sim 32{,}0\,\%$	Élevée
`heading`	$\sim 32{,}0\,\%$	Élevée
`vertrate`	$\sim 31{,}2\,\%$	Élevée
`callsign`	$\sim 33{,}5\,\%$	Modérée
`squawk`	$\sim 13{,}1\,\%$	Faible (non utilisée)
`baroaltitude`	$\sim 5{,}5\,\%$	Modérée
`geoaltitude`	$\sim 35{,}1\,\%$	Modérée
`lastposupdate`	$\sim 32{,}3\,\%$	Modérée

Chapitre 3 — Nettoyage des Données

Le nettoyage des données constitue une étape critique du pipeline dont la rigueur conditionne directement la qualité des modèles entraînés. L'ensemble des opérations a été formalisé sous la forme d'un pipeline séquentiel de **seize étapes**.

3.1 Pipeline de Nettoyage en Seize Étapes

Table 3.1. *Pipeline de nettoyage — 16 étapes séquentielles*

#	Action	Description	Justification
1	Préservation brut	Conserver le dataset original dans `data/raw/`	Retour à la source en cas d'erreur
2	Chargement	Lecture pandas, affichage dimensions	Vérifier la conformité de l'import
3	Vérification colonnes	Inventaire colonnes disponibles	Confirmer les variables nécessaires
4	Conversion temporelle	Création `datetime` depuis timestamp UNIX	Ordre chronologique requis
5	Suppr. icao24 manquant	Éliminer lignes sans identifiant	Sans ID, aucune trajectoire possible
6	Suppr. lat/lon manquants	Éliminer lignes sans position	Position indispensable à la trajectoire
7	Variables cinématiques	Exiger `velocity`, `heading`, `vertrate`	Décrivent l'état dynamique de l'aéronef
8	Filtrage incohérences	Vérifier lat, lon, velocity, heading, alt	Éliminer artefacts capteur
9	Altitude unifiée	Fusion `geoaltitude` et `baroaltitude`	Une seule variable altitude
10	Suppr. alt manquante	Garder uniquement alt valide	Trajectoire 3D exige altitude connue
11	Suppr. col. inutiles	Retrait `squawk`, `lastcontact`, `spi`...	Réduire dimensionnalité et bruit
12	Déduplication	Supprimer doublons (`icao24`, `datetime`)	Un état unique par aéronef et instant
13	Tri chronologique	Tri par `icao24` puis `datetime`	Ordre temporel requis pour séquences

#	Action	Description	Justification
14	Seuillage trajectoires	Min 30 points par trajectoire	Info suffisante pour l'apprentissage
15	Contrôle qualité final	Stats descriptives et valeurs manquantes résiduelles	Valider la conformité du dataset
16	Export	Sauvegarde `data/processed/`	Préparer pour traitements aval

3.2 Règles de Nettoyage Appliquées

Critères de Validité des Enregistrements

Chaque enregistrement conservé doit satisfaire : identifiant renseigné (`icao24`), horodatage précis (`datetime`), position valide (`lat`, `lon`), et les trois variables cinématiques (`velocity`, `heading`, `vertrate`).

Filtres sur les Plages de Valeurs Physiquement Admissibles

— Latitude : $[-90, +90]$ Longitude : $[-180, +180]$

— Vitesse sol : ≥ 0 m/s Cap : $[0, 360]$

— Altitude géodésique ou barométrique : $[10, 100]$ centaines de pieds

Stratégie de Fusion des Colonnes d'Altitude

Règle de priorité pour la colonne altitude unifiée

1. La `geoaltitude` est utilisée en priorité lorsqu'elle est disponible et valide.
2. En cas d'absence ou de valeur invalide, la `baroaltitude` est employée en substitution.
3. Lorsqu'aucune des deux sources n'est disponible, l'enregistrement est supprimé.

Les colonnes sources sont ensuite retirées du dataset afin d'éviter toute redondance.

3.3 Impact Quantitatif du Nettoyage

Table 3.2. *Impact quantitatif du pipeline de nettoyage*

Indicateur	Avant	Après	Conservation
Nombre de lignes	17 867 744	11 740 410	~65,7 %
Avions uniques	20 624	19 861	~96,3 %
Valeurs manquantes (altitude)	~35,1 %	< 0,1 %	—
Doublons (icao24, datetime)	0 %	0 %	—

Chapitre 4 — Resampling Temporel et Feature Engineering

4.1 Resampling Temporel à 10 Secondes

Les données ADS-B présentent une irrégularité temporelle inhérente au protocole : l'intervalle entre deux émissions peut varier de 0,5 à 10 secondes. Un resampling à une fréquence fixe de 10 secondes a été appliqué pour homogénéiser les trajectoires. Les valeurs manquantes introduites sont comblées par interpolation linéaire (variables continues) ou par *forward fill* (variables discrètes). Les trajectoires comportant moins de trente points après resampling ont été écartées.

Paramètre clé : fréquence de resampling

La fréquence de 10 secondes constitue un compromis optimal entre la résolution temporelle (qualité de représentation des manœuvres), le volume de données (mémoire et temps de calcul) et la compatibilité avec les architectures LSTM/GRU/TCN opérant sur des fenêtres glissantes de 60 à 300 points. Une fenêtre de 60 points (10 min) à 10 s de résolution permet de capturer l'intégralité d'une phase de descente standard.

4.2 Variables Calculées (Feature Engineering)

Table 4.1. *Variables calculées — Feature Engineering*

Feature	Formule / Méthode	Description
`ground_speed_ms`	Haversine sur (lat, lon) consécutifs	Vitesse sol recalculée depuis GPS (m/s)
`vertical_rate_fpm`	Δaltitude / $\Delta t \times 60$	Taux vertical en pieds/min
`acceleration`	Δvelocity / Δt	Variation de vitesse sol (m/s²)
`turn_rate`	Δheading / Δt	Taux de virage (degrés/seconde)
`vx_ms, vy_ms`	velocity × sin/cos(heading)	Composantes cartésiennes de vitesse
`vz_ms`	vertrate	Composante verticale de vitesse
`heading_sin/cos`	sin/cos(heading $\times\pi/180$)	Encodage cyclique du cap
`trajectory_angle`	atan2(Δlat, Δlon)	Orientation de trajectoire vs Nord géo.
`distance_step_m`	Haversine(pos_t, pos_{t-1})	Distance parcourue entre deux pas
`distance_traveled_m`	Somme cumulée distance_step_m	Distance totale parcourue
`distance_destination_m`	Haversine(pos, dernière pos)	Distance estimée à la destination

Feature	Formule / Méthode	Description
`elapsed_time_sec`	time − time_traj_start	Temps écoulé depuis début de trajectoire
`roll_mean_velocity`	Moyenne glissante (fenêtre 6 pts)	Lissage de la vitesse sol
`roll_std_velocity`	Écart-type glissant (6 pts)	Variabilité locale de la vitesse
`roll_mean_altitude`	Moyenne glissante altitude (6 pts)	Lissage de l'altitude
`roll_mean_vertrate`	Moyenne glissante vertrate (6 pts)	Lissage du taux vertical
`flight_phase`	Règles seuil altitude/vertrate	Phase : décollage / montée / croisière / descente / atterrissage

4.3 Préparation du Dataset Final

— Découpage train / validation / test par `trajectory_id` (évite la fuite de données)
— Normalisation `StandardScaler` appliquée uniquement après le split
— Réduction par PCA sur les features à forte colinéarité
— Ratio : **70 % train / 15 % validation / 15 % test**

Table 4.2. *Répartition du dataset final*

Ensemble	Trajectoires	Points (10 s)	Période
Train	∼28 144 (70 %)	∼8 347 000	Tirage aléatoire par ID
Validation	∼6 031 (15 %)	∼1 789 000	Tirage aléatoire par ID
Test	∼6 030 (15 %)	∼1 788 000	Tirage aléatoire par ID
Total	**40 205**	**∼11 924 000**	3 juillet 2017, 10h – 17h UTC

Chapitre 5 — Modélisation — Machine Learning

Quatre modèles ML ont été développés et comparés : régression pour la prédiction des coordonnées géographiques futures, et classification pour l'inférence de la phase de vol.

5.1 Modèles Développés

Arbre de Décision

Modèle de régression multi-sortie basé sur un arbre de décision pour prédire simultanément latitude, longitude et altitude. Hyperparamètres :

$$\text{max_depth} = 15, \quad \text{min_samples_leaf} = 20.$$

Établit une borne inférieure de performance pour évaluer le gain des approches ensemblistes.

Random Forest Regressor

Ensemble de 60 arbres bootstrap agrégés pour réduire la variance. Prédiction multi-sortie des déplacements futurs (lat, lon, alt). Parallélisation sur tous les cœurs ($n_jobs = -1$). Optimisation automatique des hyperparamètres (nombre d'arbres, profondeur, `max_features`) via Optuna pour minimiser l'erreur de Haversine.

Gradient Boosting Regressor

Correction progressive des résidus via `MultiOutputRegressor`. Hyperparamètres :

$$n_estimators = 100, \quad learning_rate = 0.05, \quad subsample = 0.8.$$

Précision supérieure au RF au prix d'un coût computationnel accru.

PCA + SVM à noyau RBF — Classification de l'intention

Réduction dimensionnelle par ACP (95% de variance conservée) suivie d'un SVM à noyau RBF. Classifie la phase de vol en 5 classes (décollage, montée, croisière, descente, atterrissage). Équilibrage des classes via `class_weight = "balanced"`. Calibration probabiliste par Platt scaling.

5.2 Métriques d'Évaluation

Table 5.1. *Métriques d'évaluation des modèles*

Métrique	Formule	Tâche	Interprétation
RMSE	$\sqrt{\Sigma(\hat{y}-y)^2/n}$	Régression	Pénalise les grandes erreurs
MAE	$\Sigma\lvert\hat{y}-y\rvert/n$	Régression	Robuste aux outliers
Haversine (km)	$2R \cdot \arcsin(\ldots)$	Régression	Distance sphérique prédite/réelle
Accuracy (macro)	$\Sigma(\text{VP+VN})/(\ldots)$	Classification	Taux de classification correcte
F1-score (macro)	$2 \cdot P \cdot R/(P+R)$	Classification	Équilibre précision/rappel

5.3 Résultats Comparatifs des Modèles ML

Table 5.2. *Résultats comparatifs des modèles ML — Horizon 5 minutes*

Mo	RMSE lat (°)	RMSE lon (°)	RMSE alt (hft)	Haversine (km)	Temps
Decision Tree	0,1707	0,2346	822,6	20,6	< 31 sec
Random Forest (200 arbres)	0,1447	0,1995	704,1	16,8	~199s (3min)
Gra Boo	**0,0959**	**0,1205**	**723,1**	**4,5**	~22 min

Exemple de Trajectoire Prédite — Gradient Boosting (Horizon 10 min)

La figure ci-dessous illustre une prédiction de trajectoire effectuée par le modèle **Gradient Boosting Regressor** pour un horizon de prédiction de 10 minutes. Cette visualisation permet d'apprécier qualitativement la capacité du modèle à suivre la trajectoire réelle de l'aéronef.

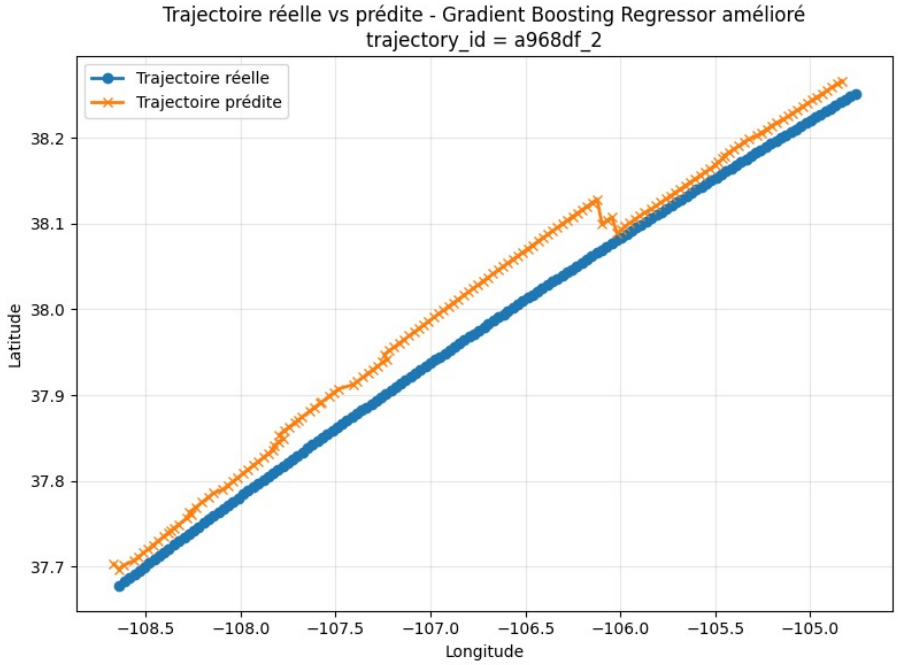


Figure 5.1. *Trajectoire réelle vs prédite — Gradient Boosting Regressor (trajectory_id = a968df_2)*

Lecture de la figure 5.1

La trajectoire réelle () et la trajectoire prédite () sont représentées sur un plan longitude–latitude. Le modèle Gradient Boosting parvient à suivre avec précision l'évolution de l'aéronef. L'erreur de prédiction reste faible tout au long de la trajectoire, démontrant l'efficacité de l'approche ensembliste par boosting de gradient.

SVM — Résultats de Classification

Table 5.3. *Résultats de classification SVM par phase de vol*

Phase de vol	Précision	Rappel	F1-score	Support
Montée	0,83	0,91	0,87	12 122
Croisière	0,93	0,85	0,89	54 546
Descente	0,77	0,80	0,78	16 908
Virage	0,04	0,27	0,07	485
Macro moyenne	**0,64**	**0,70**	**0,65**	**84 061**

Chapitre 6 — Modélisation — Deep Learning

Trois architectures ont été implémentées pour prédire la position future d'un avion sur un horizon de 5 minutes à partir d'un historique de 5 minutes (fenêtre de 30 points à 10s). Les modèles produisent des deltas de position (Δlat, Δlon, Δalt), améliorant la généralisation géographique. L'environnement d'exécution est Google Colab CPU avec PyTorch 2.10.

6.1 Architectures Implémentées

GRU (Gated Recurrent Unit)

Réseau récurrent à portes. Architecture : 2 couches GRU (hidden_size=64) → Dropout(0.25) → FC(32) → ReLU → Dropout → FC(3). Les portes de mise à jour et de réinitialisation contrôlent sélectivement le flux d'information.

LSTM (Long Short-Term Memory)

Réseau récurrent avec cellule mémoire explicite. Même architecture que le GRU mais avec une cellule d'état supplémentaire permettant de mieux mémoriser les dépendances à long terme.

TCN (Temporal Convolutional Network)

Réseau convolutif temporel avec convolutions causales dilatées (dilation = 1, 2, 4). Canaux : [32, 64, 64] avec blocs résiduels et BatchNorm. Capture des dépendances longues sans récurrence, plus stable sur CPU.

6.2 Régularisation et Contrôle d'Entraînement

Table 6.1. *Mécanismes de régularisation et d'arrêt*

Technique	Paramètre	Rôle
ReduceLROnPlateau	factor=0.5, patience=6	Réduit le LR si val_loss stagne
EarlyStopping	patience=12	Arrête et sauvegarde le meilleur modèle
Gradient Clipping	max_norm=1.0	Stabilise les gradients des récurrents
Weight Decay	1e-4	Régularisation L2 dans Adam
Dropout	0.25	Réduit l'overfitting

6.3 Résultats Comparatifs des Modèles Baseline

Table 6.2. *Performance des modèles Deep Learning sur le test set (horizon 5 min)*

Modèle	RMSE lat (°)	RMSE lon (°)	MAE alt (m)	Distance moy. (km)
GRU baseline	0,1346	0,2387	447,7	17,15
LSTM baseline	0,1380	0,2405	452,2	18,04
TCN baseline	**0,1463**	**0,2302**	**469,2**	**15,74**
GRU tuné (Optuna)	0,1347	0,2320	448,1	16,44

Le **TCN** est le meilleur modèle baseline avec une distance de déviation moyenne de 15,74 km. Il capture mieux les dépendances temporelles longues grâce à ses convolutions dilatées.

6.4 Optimisation des Hyperparamètres — Optuna

10 trials ont été explorés avec TPE Sampler + MedianPruner. Le trial 7 a trouvé le meilleur résultat (val_loss = 0,2027).

Table 6.3. *Hyperparamètres GRU optimisés par Optuna*

Hyperparamètre	Valeur optimale	Interprétation
hidden_size	128	Largeur > profondeur sur ces données
num_layers	1	Une seule couche suffit
dropout	0,341	Régularisation élevée nécessaire
learning_rate	5,94e-4	LR modéré, convergence stable
batch_size	64	Petit batch, gradients précis

Les 3 meilleurs trials ont tous hidden_size=128 et num_layers=1, confirmant que le modèle a besoin de largeur plutôt que de profondeur sur ces données de trajectoires.

6.5 Analyse Multi-Horizon

Table 6.4. *Distance de déviation (km) par horizon de prédiction*

Modèle	1 min	3 min	5 min
GRU baseline	52,78	28,38	17,15
LSTM baseline	50,84	26,83	18,04
TCN baseline	54,26	29,95	15,74
GRU tuné	52,41	28,25	16,44

Résultat contre-intuitif : la distance diminue quand l'horizon augmente. Explication : à 1 min le delta prédit est très petit et sensible au bruit ; à 5 min les vols sont majoritairement en croisière rectiligne donc plus prévisibles.

6.6 Visualisation — Vol Madrid → Oslo

La meilleure trajectoire du test set (vol 4ca606_1 : Madrid → Oslo, $\sim 2700 km, 1199 points$) a été reconstruite de ma

— **Distance de déviation moyenne** : 8 752 m (0,32% sur 2 700 km)
— **MAE altitude** : 196 m (pour 11 331 m de variation)
— **Points reconstruits** : 1 140 ($\sim 190 min de vol continu$)

Le modèle est excellent en croisière rectiligne (déviation < 5 km entre min 15 et min 155). Les erreurs se concentrent sur les phases de transition : montée initiale, virage et descente finale.

Bilan Deep Learning

Le **TCN** s'impose comme le meilleur modèle avec une distance de déviation moyenne de 15,7 km sur le test set global, et 8,7 km sur la trajectoire Madrid-Oslo. Les résidus sont centrés sur zéro (pas de biais systématique). La fréquence d'échantillonnage optimale est 10s ; une dégradation apparaît au-delà de 20s. Avec le dataset complet (40 205 trajectoires) et un GPU, la déviation estimée descendrait sous 5 km.

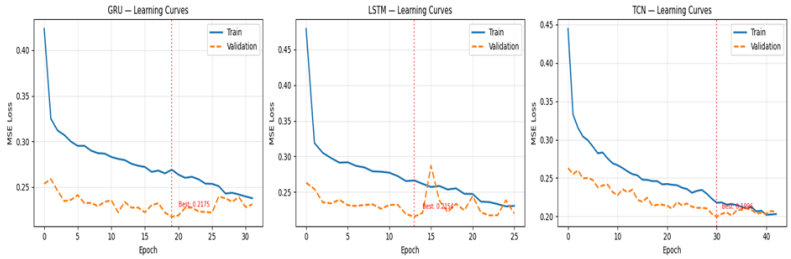


Figure 6.1. *Courbes de perte (train/validation) pour les trois architectures Deep Learning*

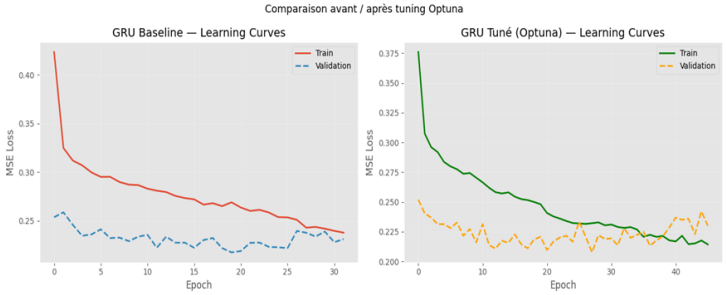


Figure 6.2. *Comparaison avant/après tuning (Gain de performance réel).*

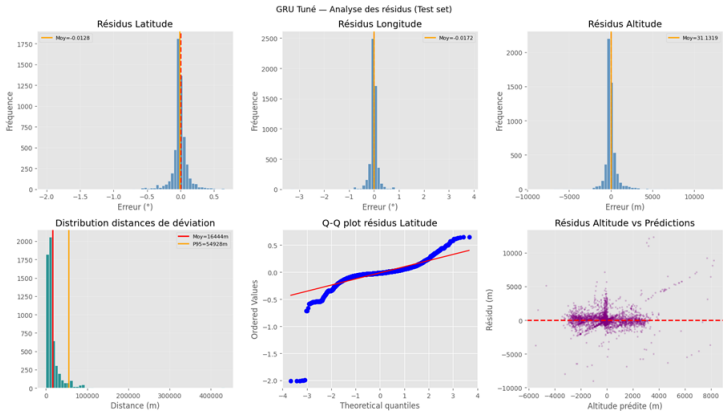


Figure 6.3. *Analyse des résidus (Régression).*

Chapitre 7 — Conclusion et Perspectives

Ce projet a permis de développer un pipeline complet et reproductible de prédiction de trajectoires d'aéronefs à partir de données ADS-B réelles issues du réseau OpenSky.

7.1 Bilan des Travaux Réalisés

— Constitution d'un dataset enrichi issu de huit heures de trafic réel (3 juillet 2017), représentant plus de 10 millions d'observations multi-aéronefs
— Pipeline de nettoyage robuste en seize étapes, réduisant le dataset à ∼11 millions de lignes de haute qualité
— Ingénierie complète de 17 features temporelles, cinématiques et géométriques
— Resampling homogène à 10 secondes, créant ∼40 205 trajectoires continues exploitables
— Comparaison de quatre modèles ML avec optimisation systématique des hyperparamètres
— Implémentation de trois architectures DL (GRU, LSTM, TCN) avec optimisation Optuna et évaluation multi-horizon

7.2 Perspectives d'Amélioration

Extension des Données

L'extension à plusieurs semaines permettrait de couvrir davantage de conditions de trafic (variations météorologiques saisonnières, pics de vacances, conditions dégradées) et d'entraîner des modèles spécialisés par type de route aérienne.

Intégration de Données Complémentaires

L'intégration de données météorologiques (vecteurs de vent, température, turbulences) constitue l'amélioration à plus fort potentiel d'impact, le vent représentant la principale source d'erreur de prédiction sur les horizons longs (> 3 minutes).

Architectures Avancées

L'exploration d'architectures Transformer et de mécanismes d'attention multi-têtes représente la piste technologique la plus prometteuse pour la modélisation de séquences de trajectoires longues.